Mentee: Yovina Silvia Mentor: Bilal Benefit



TASK 3 - Ingestion Airbyte

1. Ingest data from local file json to Postgresql with Airbyte.

Berikut adalah langkah-langkah untuk memasukkan data dari file lokal JSON ke PostgreSQL menggunakan Airbyte:

1. Instal Airbyte:

o Unduh dan instal Airbyte di sistem dengan mengikuti panduan instalasi resmi di situs web Airbyte atau gunakan airbyte di web.

2. Jalankan Airbyte:

- o Setelah instalasi, jalankan Airbyte dengan perintah docker-compose up
- o Airbyte akan berjalan di latar belakang dan dapat diakses melalui browser di http://localhost:8000.

3. Konfigurasikan Sumber Data (Source):

- o Buka Airbyte di browser dan masuk ke dashboard.
- o Klik pada "Sources" dan pilih "New Source".
- o Pilih tipe sumber data sebagai "Local JSON".
- o Isi detail koneksi seperti:
 - Nama Sumber
 - Path file JSON lokal di sistem kita

4. Konfigurasikan Tujuan Data (Destination):

- o Klik pada "Destinations" dan pilih "New Destination".
- o Pilih tipe tujuan data sebagai "PostgreSQL".
- o Isi detail koneksi PostgreSQL seperti:
 - Host
 - Port
 - Nama Pengguna
 - Kata Sandi
 - Nama Database

5. Buat Koneksi:

- o Setelah sumber dan tujuan dikonfigurasi, buat koneksi antara keduanya.
- o Klik pada "Connections" dan pilih "New Connection".
- o Pilih sumber data JSON yang telah kita konfigurasi.
- o Pilih tujuan data PostgreSQL yang telah dikonfigurasi.
- o Atur mode sinkronisasi (misalnya: Full Refresh, Incremental).

Mentee: Yovina Silvia Mentor: Bilal Benefit



6. Jadwalkan Sinkronisasi:

- o Atur jadwal sinkronisasi sesuai kebutuhan (misalnya, sinkronisasi harian, mingguan, atau manual).
- o Simpan konfigurasi.

7. Mulai Sinkronisasi:

- o Setelah semua konfigurasi selesai, mulai proses sinkronisasi dengan mengklik tombol "Sync Now" pada halaman koneksi.
- o Airbyte akan mulai memindahkan data dari file JSON ke database PostgreSQL sesuai dengan konfigurasi yang telah dibuat.

8. Monitor dan Verifikasi:

- o Pantau proses sinkronisasi melalui dashboard Airbyte.
- o Verifikasi data di PostgreSQL untuk memastikan bahwa data telah dimasukkan dengan benar

Mentee: Yovina Silvia Mentor: Bilal Benefit



a. Jalankan dulu docker-compose.yml yang menjalankan container-container di citus dan airbyte

| Name | Image | Status | Port(s) | CPU (%) | Last started |
|---|--|---------------|------------------------------------|---------|----------------|
| ingestion_airbyte | | Running (13/1 | ı | 7.28% | 34 seconds ago |
| airbyte-temporal 7c02541a9843 🗈 | airbyte/temporal:0.50.20 | Running | | 2.53% | 46 seconds ago |
| ingestion_airbyte_mas 0738fa4ba013 🖺 | g citusdata/citus:12.0.0 | Running | <u>15432:5432</u> 🗹 | 0.03% | 46 seconds ago |
| airbyte-db 04805a496ae0 ℃ | airbyte/db:0.50.20 | Running | | 0.03% | 46 seconds ago |
| ingestion_airbyte bf6e5fa56c36 ① | postgres:12.16 | Running | <u>5439:5432</u> [2] | 0.05% | 46 seconds ago |
| init 527050b2e6fb © | airbyte/init:0.50.20 | Exited | | 0% | 46 seconds ago |
| airbyte-bootloader 6ac6e7c291d4 🖰 | airbyte/bootloader:0.50.20 | Exited | | 0% | 45 seconds ago |
| airbyte-api-server 8c711ce5bba8 🗈 | airbyte/airbyte-api-server:0.50.20 | Running | | 0.11% | 35 seconds ago |
| e3a3371cb70f © | airbyte/webapp:0.50.20 | Running | | 0% | 35 seconds ago |
| ingestion_airbyte_man 47d42d131e7f 🖺 | i citusdata/membership-manager:0.3.0 | Running | | 3.99% | 45 seconds ago |
| airbyte-connector-buil adf93e4fddf8 ① | g airbyte/connector-builder-server:0.50.20 | Running | 64224:80 [2] | 0.09% | 35 seconds ago |
| airbyte-server 54f31ead5a30 ① | airbyte/server:0.50.20 | Running | <u>64225:8001</u> [Z] | 0.09% | 35 seconds ago |





| DATA ENGINEE | N DAICH 4 | | | | | | alterra |
|--------------|-----------|---|--|---------|-------------------------------------|---------|----------------|
| | Name | | Image | Status | Port(s) | CPU (%) | Last started |
| | | ingestion_airbyte bf6e5fa56c36 ① | <u>postgres:12.16</u> | Running | <u>5439:5432</u> [2] | 0.05% | 1 minute ago |
| | | init 527050b2e6fb | airbyte/init:0.50.20 | Exited | | 0% | 1 minute ago |
| | | airbyte-bootloader 6ac6e7c291d4 🗓 | airbyte/bootloader:0.50.20 | Exited | | 0% | 59 seconds ago |
| | | airbyte-api-server 8c711ce5bba8 🗓 | airbyte/airbyte-api-server:0.50.20 | Running | | 0.1% | 50 seconds ago |
| | | airbyte-webapp e3a3371cb70f | airbyte/webapp:0.50.20 | Running | | 0% | 49 seconds ago |
| | | ingestion_airbyte_man: 47d42d131e7f 🗅 | citusdata/membership-manager:0.3.0 | Running | | 0.59% | 1 minute ago |
| | | airbyte-connector-build adf93e4fddf8 🗓 | airbyte/connector-builder-server:0.50.20 | Running | 64224:80 [2] | 0.12% | 49 seconds ago |
| | | airbyte-server 54f31ead5a30 | airbyte/server:0.50.20 | Running | <u>64225:8001</u> [Z] | 0.11% | 49 seconds ago |
| | | airbyte-cron 80fd6ccbd611 🗇 | airbyte/cron:0.50.20 | Running | | 0.12% | 49 seconds ago |
| | | airbyte-proxy ff3768d1bd0b 🖺 | airbyte/proxy:0.50.20 | Running | 8000:8000 [2] Show all ports (4) | 0% | 49 seconds ago |
| | | airbyte-worker 912507cc36d3 🗇 | airbyte/worker:0.50.20 | Running | | 0.17% | 50 seconds ago |
| | | citus-worker-1 9509fbd23d98 | citusdata/citus:12.0.0 | Running | | 3.35% | 59 seconds ago |

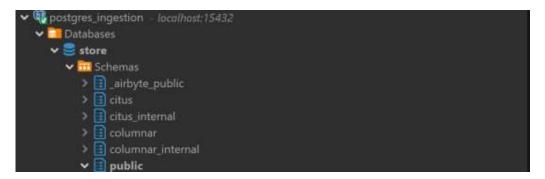
Mentee: Yovina Silvia Mentor: Bilal Benefit



b. Buat database untuk data raw di postgres (contoh nama db = postgres_raw), sesuaikan portnya dengan yg sudah disetting di docker compose tadi



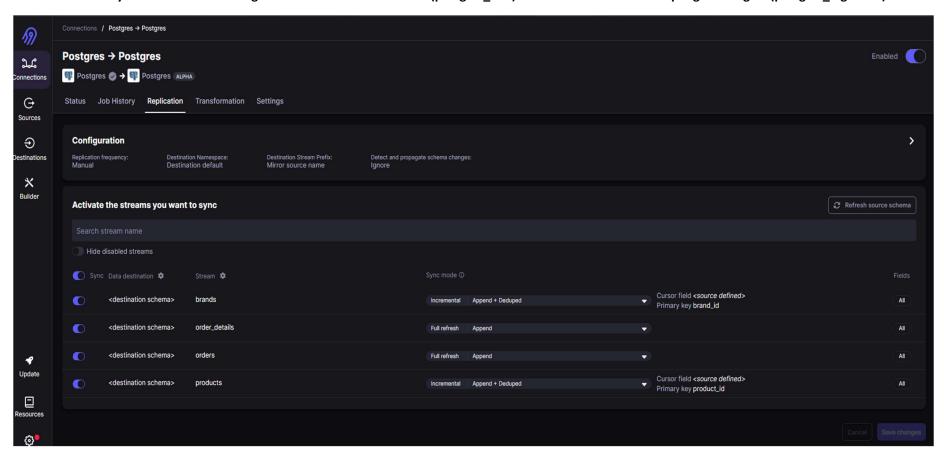
c. Buat database untuk menampung data yg sudah diingest di postgres (contoh nama db = postgres_ingestion), dan juga sesuaikan portnya dengan yg sudah disetting di docker compose tadi



Mentee: Yovina Silvia Mentor: Bilal Benefit



d. Gunakan airbyte untuk melakukan ingestion data dari database raw (postgres_raw) ke database untuk menampung hasil ingest (postgres_ingestion)



Mentee: Yovina Silvia Mentor: Bilal Benefit



Airbyte menawarkan beberapa mode sinkronisasi (sync mode) yang dapat digunakan untuk mengontrol bagaimana data dipindahkan dari sumber ke tujuan. Berikut adalah penjelasan mengenai mode-mode sinkronisasi yang tersedia di Airbyte:

1. Full Refresh - Overwrite:

- Deskripsi: Mode ini akan mengambil seluruh data dari sumber setiap kali sinkronisasi dijalankan dan menimpa semua data yang ada di tujuan.
- Kelebihan: Berguna untuk dataset yang relatif kecil dan ketika ingin memastikan bahwa data di tujuan selalu merupakan salinan terbaru dari sumber.
- o **Kekurangan:** Tidak efisien untuk dataset yang besar karena semua data akan ditimpa setiap kali sinkronisasi dilakukan.

2. Full Refresh - Append:

- o **Deskripsi:** Mode ini akan mengambil seluruh data dari sumber setiap kali sinkronisasi dijalankan dan menambahkan data tersebut ke tujuan tanpa menghapus data yang sudah ada.
- o Kelebihan: Berguna ketika kita perlu menyimpan semua versi data sebelumnya di tujuan.
- Kekurangan: Ukuran data di tujuan akan terus bertambah seiring waktu, yang dapat menyebabkan masalah penyimpanan dan kinerja.

3. Incremental - Append:

- o Deskripsi: Mode ini hanya mengambil data baru atau data yang diubah sejak sinkronisasi terakhir dan menambahkannya ke tujuan.
- o Kelebihan: Efisien dalam hal penggunaan sumber daya karena hanya data yang berubah yang dipindahkan. Cocok untuk dataset yang besar.
- **Kekurangan:** Memerlukan sumber data yang mendukung penelusuran perubahan atau timestamp untuk mendeteksi data baru atau yang diubah.

4. Incremental - Deduped + History:

- o **Deskripsi:** Mode ini juga hanya mengambil data baru atau data yang diubah sejak sinkronisasi terakhir, tetapi menyimpan riwayat perubahan di tujuan.
- o **Kelebihan:** Selain efisien, mode ini memungkinkan kita untuk melacak perubahan data dari waktu ke waktu di tujuan.
- o **Kekurangan:** Memerlukan penyimpanan lebih besar di tujuan untuk menyimpan riwayat perubahan.

Memilih Mode Sinkronisasi:

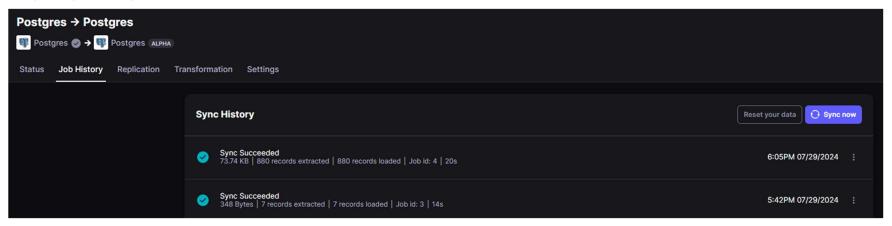
- Full Refresh Overwrite cocok untuk dataset yang tidak terlalu besar dan ketika kita selalu ingin data di tujuan merupakan salinan terbaru dari sumber.
- Full Refresh Append cocok untuk situasi di mana kita perlu menyimpan semua versi data sebelumnya.
- Incremental Append sangat berguna untuk dataset yang besar atau ketika hanya sedikit data yang berubah setiap kali sinkronisasi.
- Incremental Deduped + History ideal untuk pelacakan perubahan data dari waktu ke waktu dan analisis historis.

Mentee: Yovina Silvia Mentor: Bilal Benefit



Memilih mode sinkronisasi yang tepat tergantung pada kebutuhan spesifik kita terkait dengan ukuran dataset, frekuensi perubahan data, dan kebutuhan pelacakan historis.

Tampilan Sync History



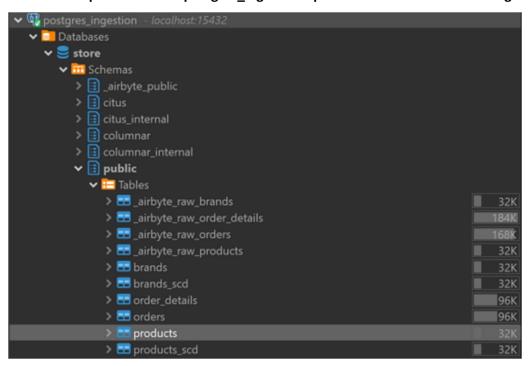
Sync history pada Airbyte mencakup berbagai informasi penting yang membantu melacak dan mengelola proses sinkronisasi data. Berikut adalah beberapa informasi yang biasanya ditemukan dalam sync history Airbyte:

- 1. Waktu Sinkronisasi: Timestamp menunjukkan kapan sinkronisasi dimulai dan selesai.
- 2. **Status Sinkronisasi**: Apakah sinkronisasi berhasil atau gagal.
- 3. **Durasi Sinkronisasi**: Berapa lama waktu yang diperlukan untuk menyelesaikan sinkronisasi.
- 4. **Jumlah Data yang Diproses**: Berapa banyak record atau baris data yang telah diproses selama sinkronisasi.
- 5. Error Messages: Jika ada kegagalan, pesan error atau log yang terkait dengan kegagalan tersebut.
- 6. **Sumber dan Tujuan**: Informasi tentang sumber data (misalnya, database atau API) dan tujuan data (misalnya, data warehouse atau sistem analitik).
- 7. Versi Konfigurasi: Versi dari konfigurasi atau konektor yang digunakan selama sinkronisasi.
- 8. Pengguna yang Memulai Sinkronisasi: Informasi tentang pengguna atau sistem yang memulai sinkronisasi.
- 9. Perubahan pada Konfigurasi: Log atau catatan tentang perubahan pada konfigurasi sinkronisasi.

Mentee: Yovina Silvia Mentor: Bilal Benefit



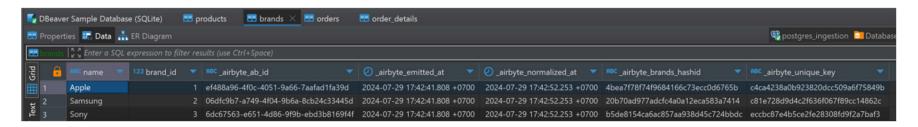
e. Lalu cek pada database postgres_ingestion apakah data sudah berhasil diingest oleh airbyte



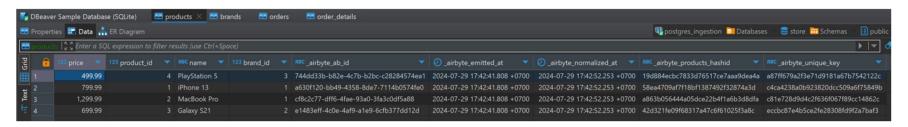
Mentee: Yovina Silvia Mentor: Bilal Benefit



f. Table brands



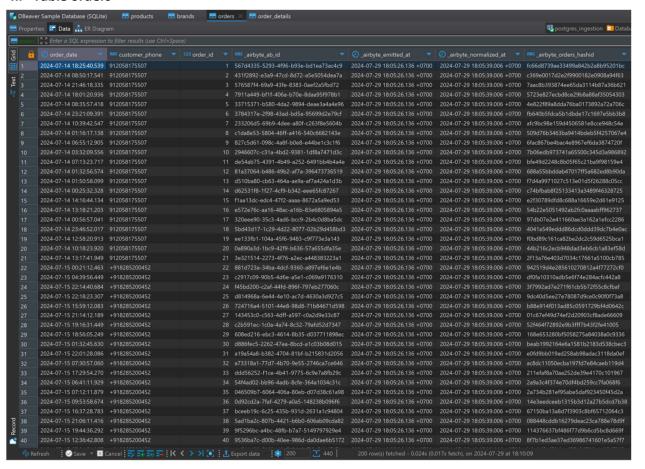
g. Table products



Mentee: Yovina Silvia Mentor: Bilal Benefit

alterra academy

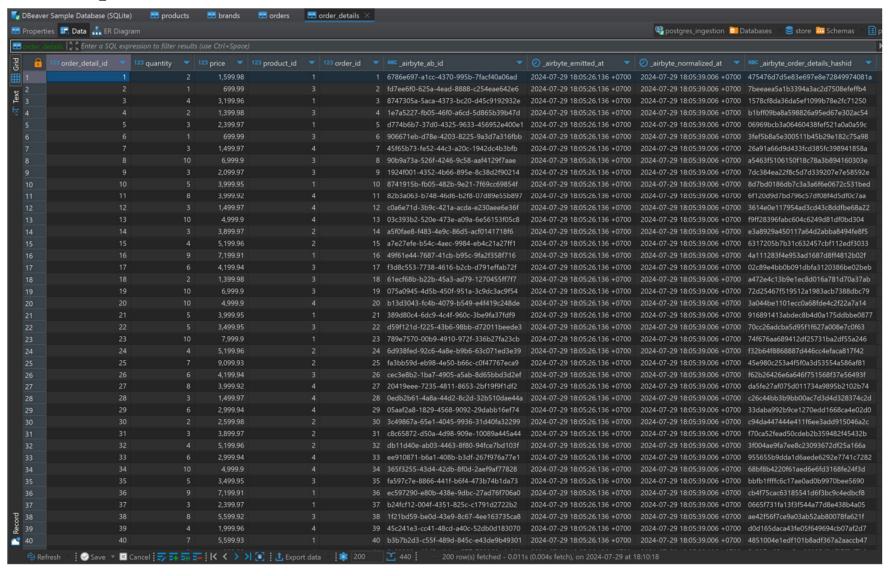
h. Table orders



Mentee: Yovina Silvia Mentor: Bilal Benefit



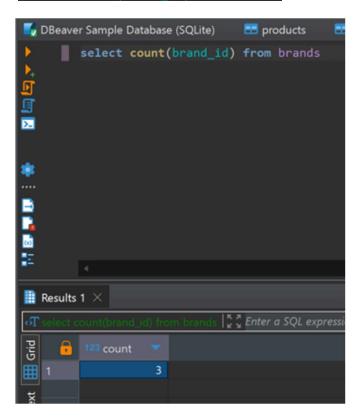
i. Table order_details



Mentee: Yovina Silvia Mentor: Bilal Benefit

- 2. Count the number of rows ingested.
 - a. Row ingested on table brands

select count(brand_id) from brands



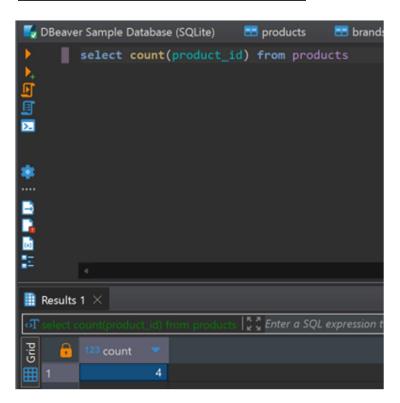


Mentee: Yovina Silvia Mentor: Bilal Benefit



b. Row ingested on table products

select count(product_id) from products

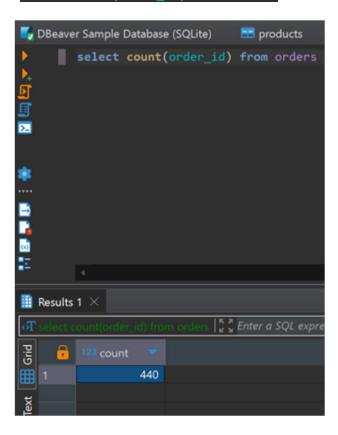


Mentee: Yovina Silvia Mentor: Bilal Benefit



c. Row ingested on table orders

select count(order_id) from orders



Mentee: Yovina Silvia Mentor: Bilal Benefit



d. Row ingested on table order_details

select count(order_detail_id) from order_details

